

Sistemas de Comunicações Digitais

Curso de Graduação em Engenharia de Telecomunicações

Universidade Federal do Ceará

Semestre 2017.2


Parte 1

Introdução e revisão de processos estocásticos


Conteúdo

- 1 **Introdução às comunicações digitais**
- 2 Probabilidade e variáveis aleatórias


Modulações analógicas e digitais




O que é comunicação digital?




(a)



(b)




(c)




(d)


Por quê comunicação digital?



Por quê comunicação digital?




Repetidor regenerativo




- Comunicações digitais: os sinais transmitidos pertencem a um conjunto finito de formas de onda \Rightarrow O sinal distorcido pode ser recuperado para a sua forma ideal, portanto removendo totalmente o ruído.
- Comunicações analógicas: os sinais transmitidos são formas de onda analógicas, as quais podem assumir uma variedade infinita de formas \Rightarrow Uma vez distorcido o sinal, a distorção dificilmente pode ser removida.

Diagrama de blocos de um sistema de comunicação



(a)



Digital vs. Analógico

- Vantagens:
 - Sinais digitais são mais fáceis de serem regenerados.
 - Circuitos digitais estão menos sujeitos a distorção e interferência.
 - Circuitos digitais são mais confiáveis e podem ser produzidos a um custo menor do que circuitos analógicos.
 - A implementação de hardware digital é mais flexível que a de hardware analógico.
 - Sinais digitais podem se beneficiar de técnicas de processamento digital de sinais.
- Desvantagens:
 - Processamento de sinais mais intenso.
 - A sincronização é uma questão crucial.
 - Requer maior banda de transmissão.
 - Degradação não-suave.

Conteúdo

- 1 Introdução às comunicações digitais
- 2 Probabilidade e variáveis aleatórias**

Espaço amostral e probabilidade

- *Experimento aleatório*: seu resultado, por algum motivo, não pode ser previsto com absoluta certeza.
- Exemplos: arremesso de um dado ou moeda, ou retirada de uma carta de uma pilha.
- *Espaço amostral*: o conjunto de todos os possíveis resultados, denotado por Ω . Os resultados individuais são denotados por ω , onde $\omega \in \Omega$.
- Um espaço amostral pode ser *discreto* ou *contínuo*.
- *Eventos* são subconjuntos do espaço amostral para os quais medidas de suas ocorrências, chamadas de probabilidades, podem ser definidas ou determinadas.

Os três axiomas da probabilidade

- Para um espaço amostral discreto Ω , define-se a medida de probabilidade P em Ω como uma função que assinala valores não-negativos a todos os eventos, denotados por E , em Ω , tal que as seguintes condições são satisfeitas:
 - Axioma 1: $0 \leq P(E) \leq 1$ para todo $E \in \Omega$.
 - Axioma 2: $P(\Omega) = 1$
 - Axioma 3: Para eventos mutuamente exclusivos, i.e., $E_i \cap E_j = \emptyset \forall i \neq j$, tem-se que
$$P\left(\bigcup_{i=1}^{\infty} E_i\right) = \sum_{i=1}^{\infty} P(E_i)$$

Propriedades importantes

- ❶ $P(E^C) = 1 - P(E)$, onde E^C denota o complemento de E . Esta propriedade implica que $P(E^C) + P(E) = 1$, ou seja, algo tem que ocorrer.
- ❷ $P(\emptyset) = 0$, novamente, alguma coisa tem que ocorrer.
- ❸ $P(E_1 \cup E_2) = P(E_1) + P(E_2) - P(E_1 \cap E_2)$. Note que se dois eventos E_1 e E_2 são mutuamente exclusivos então $P(E_1 \cup E_2) = P(E_1) + P(E_2)$.
- ❹ Se $E_1 \subseteq E_2$ então $P(E_1) \leq P(E_2)$.

Probabilidade condicional

- Observamos o evento E_1 , mas na verdade estamos interessados no evento E_2 : o conhecimento de que E_1 ocorreu altera a probabilidade de que E_2 ocorra.
- Se antes tinha-se $P(E_2)$, agora tem-se $P(E_2|E_1)$, ou seja, a probabilidade de que E_2 ocorra dado que E_1 ocorreu.
- A probabilidade condicional é dada por

$$P(E_2|E_1) = \begin{cases} \frac{P(E_2 \cap E_1)}{P(E_1)}, & \text{se } P(E_1) \neq 0 \\ 0 & \text{c.c.} \end{cases} \quad (1)$$

- Se $P(E_2|E_1) = P(E_2)$, ou $P(E_2 \cap E_1) = P(E_1)P(E_2)$, então E_1 e E_2 são ditos *estatisticamente independentes*.
- Regra de Bayes:

$$P(E_2|E_1) = \frac{P(E_1|E_2)P(E_2)}{P(E_1)} \quad (2)$$

Teorema da probabilidade total


- Os eventos $\{E_i\}_{i=1}^n$ particionam o espaço amostral Ω se:
 - $\bigcup_{i=1}^n E_i = \Omega$
 - $E_i \cap E_j = \emptyset$ para todo $1 \leq i, j \leq n$ e $i \neq j$
- Se um evento A tem probabilidades condicionais $\{P(A|E_i)\}_{i=1}^n$, $P(A)$ pode ser obtido por

$$P(A) = \sum_{i=1}^n P(E_i)P(A|E_i) \quad (3)$$

- Regra de Bayes

$$P(E_i|A) = \frac{P(A|E_i)P(E_i)}{P(A)} = \frac{P(A|E_i)P(E_i)}{\sum_{j=1}^n P(A|E_j)P(E_j)} \quad (4)$$

Variáveis aleatórias



- Uma variável aleatória é um *mapeamento* do espaço amostral Ω ao conjunto de números reais.
- Vamos expressar as variáveis aleatórias em **negrito**, i.e., \mathbf{x} , \mathbf{y} , etc., enquanto valores individuais ou específicos do mapeamento \mathbf{x} são denotados por $\mathbf{x}(\omega)$.

Função Distribuição de Probabilidade (CDF)


- A CDF fornece uma descrição completa da variável aleatória. Ela é definida como:

$$F_{\mathbf{x}}(x) = P(\omega \in \Omega \mid \mathbf{x}(\omega) \leq x) = P(\mathbf{x} \leq x). \quad (5)$$


- A CDF possui as seguintes propriedades:
 - $0 \leq F_{\mathbf{x}}(x) \leq 1$
 - $F_{\mathbf{x}}(x)$ é não decrescente: $F_{\mathbf{x}}(x_1) \leq F_{\mathbf{x}}(x_2)$ se $x_1 \leq x_2$
 - $F_{\mathbf{x}}(-\infty) = 0$ e $F_{\mathbf{x}}(+\infty) = 1$
 - $P(a < \mathbf{x} \leq b) = F_{\mathbf{x}}(b) - F_{\mathbf{x}}(a)$

Exemplos de CDFs típicas - I

- Uma variável aleatória pode ser *discreta*, *contínua* ou *mista*.



Exemplos de CDFs típicas - II



Função Densidade de Probabilidade (PDF)

- A PDF é definida como a derivada da CDF:

$$f_{\mathbf{x}}(x) = \frac{dF_{\mathbf{x}}(x)}{dx}; \quad F_{\mathbf{x}}(x) = \int_{-\infty}^x f_{\mathbf{x}}(u)du \quad (6)$$

- Segue que:

$$P(x_1 \leq \mathbf{x} \leq x_2) = P(\mathbf{x} \leq x_2) - P(\mathbf{x} \leq x_1) \quad (7)$$

$$= F_{\mathbf{x}}(x_2) - F_{\mathbf{x}}(x_1) = \int_{x_1}^{x_2} f_{\mathbf{x}}(x)dx. \quad (8)$$

- A PDF possui as seguintes propriedades:

- $f_{\mathbf{x}}(x) \geq 0$


- $\int_{-\infty}^{\infty} f_{\mathbf{x}}(x)dx = 1$

- Em geral, $P(\mathbf{x} \in \mathcal{A}) = \int_{\mathcal{A}} f_{\mathbf{x}}(x)dx$

- Para variáveis aleatórias discretas é mais comum definir a função de probabilidade de massa (pmf): $p_i = P(\mathbf{x} = x_i)$.

- Note que, para todo i , temos que $p_i \geq 0$ e $\sum_i p_i = 1$.

Variável Aleatória Gaussiana



- É uma variável aleatória contínua cuja PDF é dada por:

$$f_{\mathbf{x}}(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{(x - \mu)^2}{2\sigma^2} \right\}, \quad (9)$$

onde μ e σ^2 são parâmetros. É usualmente denotada por $\mathcal{N}(\mu, \sigma^2)$.

- É a variável aleatória mais importante e mais freqüentemente encontrada na área de comunicações.

Variável Aleatória Gaussiana

- Funções auxiliares:

$$\operatorname{erf}(x) = \frac{2}{\sqrt{\pi}} \int_0^x e^{-t^2} dt \quad (10)$$

$$\operatorname{erfc}(x) = \frac{2}{\sqrt{\pi}} \int_x^\infty e^{-t^2} dt = 1 - \operatorname{erf}(x) \quad (11)$$


$$Q(x) = \frac{1}{\sqrt{2\pi}} \int_x^\infty e^{-t^2/2} dt = \frac{1}{2} \operatorname{erfc} \left(\frac{x}{\sqrt{2}} \right) \quad (12)$$

- CDF Gaussiana:

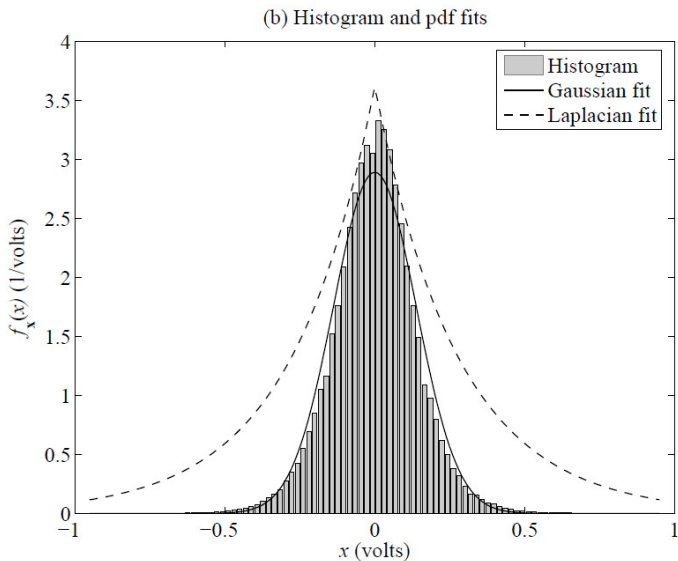
$$F_{\mathbf{x}}(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{(t - \mu)^2}{2\sigma^2} \right\} dt \quad (13)$$

$$F_{\mathbf{x}}(x) = 1 - \frac{1}{2} \operatorname{erfc} \left(\frac{x - \mu}{\sqrt{2}\sigma} \right) \quad (14)$$

Variável Aleatória Gaussiana



Variável Aleatória Gaussiana



Funções de uma variável aleatória

- A função $y = g(\mathbf{x})$ é também uma variável aleatória.
- Pela definição, a CDF de y pode ser escrita como

$$F_y(y) = P(\omega \in \Omega | g(\mathbf{x}(\omega)) \leq y), \quad (15)$$

- Assuma que para todo y , a equação $g(x) = y$ possui um número de soluções finito e em cada ponto da solução, a derivada de $g(x)$ existe e é não-nula. A PDF de $y = g(\mathbf{x})$ é dada por:

$$f_y(y) = \sum_i \frac{f_{\mathbf{x}}(x_i)}{\left| \frac{dg(x)}{dx} \right|_{x=x_i}}, \quad (16)$$

onde $\{x_i\}$ são as soluções de $g(x) = y$.

- Uma função linear de uma variável aleatória Gaussiana é também uma variável aleatória Gaussiana.

Esperança de variáveis aleatórias - I

- *Médias estatísticas*, ou *momentos*, possuem um papel importante na caracterização de uma variável aleatória.
- O *valor esperado* (também chamado de valor médio ou primeiro momento) de uma variável aleatória x é definido como:

$$m_x = E\{x\} = \int_{-\infty}^{\infty} x f_x(x) dx, \quad (17)$$

onde E denota o *operador estatístico esperança*.

- Em geral, o n -ésimo momento de x é definido como:

$$E\{x^n\} = \int_{-\infty}^{\infty} x^n f_x(x) dx. \quad (18)$$

- Para $n = 2$, $E\{x^2\}$ é conhecido como o valor médio quadrático da variável aleatória.

Esperança de variáveis aleatórias - II

- O n -ésimo *momento central* da variável aleatória \mathbf{x} é:

$$E\{\mathbf{y}\} = E\{(\mathbf{x} - m_{\mathbf{x}})^n\} = \int_{-\infty}^{\infty} (x - m_{\mathbf{x}})^n f_{\mathbf{x}}(x) dx \quad (19)$$

- Quando $n = 2$, o momento central é chamado de *variância*, comumente denotado por $\sigma_{\mathbf{x}}^2$:

$$\sigma_{\mathbf{x}}^2 = \text{var}(\mathbf{x}) = E\{(\mathbf{x} - m_{\mathbf{x}})^2\} = \int_{-\infty}^{\infty} (x - m_{\mathbf{x}})^2 f_{\mathbf{x}}(x) dx \quad (20)$$

- A variância provê uma medida da “aleatoriedade” da variável.
- A média e variância de uma variável aleatória fornecem uma *descrição parcial* de sua PDF.
- Relação entre a variância, o primeiro e o segundo momentos é dada por:

$$\sigma_{\mathbf{x}}^2 = E\{\mathbf{x}^2\} - [E\{\mathbf{x}\}]^2 = E\{\mathbf{x}^2\} - m_{\mathbf{x}}^2. \quad (21)$$

Variáveis aleatórias múltiplas - I

- Normalmente encontradas quando tratando-se experimentos combinados ou tentativas repetidas de um único experimento.
- São basicamente funções multidimensionais definidas em um espaço amostral de um experimento combinado.
- Sejam \mathbf{x} e \mathbf{y} duas variáveis aleatórias definidas em um mesmo espaço amostral Ω . A função distribuição de probabilidade conjunta é definida como:

$$F_{\mathbf{x},\mathbf{y}}(x, y) = P(\mathbf{x} \leq x, \mathbf{y} \leq y) \quad (22)$$

- De forma análoga, a função densidade de probabilidade conjunta é dada por:

$$f_{\mathbf{x},\mathbf{y}}(x, y) = \frac{\partial^2 F_{\mathbf{x},\mathbf{y}}(x, y)}{\partial x \partial y} \quad (23)$$

Variáveis aleatórias múltiplas - II

- Quando a PDF conjunta é integrada sobre uma das variáveis, uma obtém a PDF da outra variável, chamada de PDF marginal:

$$\int_{-\infty}^{\infty} f_{\mathbf{x},\mathbf{y}}(x, y) dx = f_{\mathbf{y}}(y) \quad (24)$$

$$\int_{-\infty}^{\infty} f_{\mathbf{x},\mathbf{y}}(x, y) dy = f_{\mathbf{x}}(x) \quad (25)$$

- Note que:

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f_{\mathbf{x},\mathbf{y}}(x, y) dx dy = F(\infty, \infty) = 1 \quad (26)$$

$$F_{\mathbf{x},\mathbf{y}}(-\infty, -\infty) = F_{\mathbf{x},\mathbf{y}}(-\infty, y) = F_{\mathbf{x},\mathbf{y}}(x, -\infty) = 0 \quad (27)$$

Variáveis aleatórias múltiplas - III

- A PDF condicional da variável aleatória y , dado que o valor da variável aleatória x é igual a x , é definida como:

$$f_y(y|x) = \begin{cases} \frac{f_{x,y}(x,y)}{f_x(x)}, & f_x(x) \neq 0 \\ 0, & \text{c.c.} \end{cases} \quad (28)$$

- Duas variáveis aleatórias x e y são estatisticamente independentes se e somente se:

$$f_y(y|x) = f_y(y) \quad \text{ou de forma equivalente} \quad (29)$$

$$f_{x,y}(x,y) = f_x(x)f_y(y) \quad (30)$$

- O *momento conjunto* é definido como:

$$E\{\mathbf{x}^j \mathbf{y}^k\} = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x^j y^k f_{x,y}(x,y) dx dy. \quad (31)$$

Variáveis aleatórias múltiplas - IV

- O *momento central conjunto* é:

$$E\{(\mathbf{x} - m_{\mathbf{x}})^j (\mathbf{y} - m_{\mathbf{y}})^k\} = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - m_{\mathbf{x}})^j (y - m_{\mathbf{y}})^k f_{\mathbf{x},\mathbf{y}}(x, y) dx dy, \quad (32)$$

onde $m_{\mathbf{x}} = E\{\mathbf{x}\}$ e $m_{\mathbf{y}} = E\{\mathbf{y}\}$.

- Os momentos mais importantes são:

- Correlação:

$$E\{\mathbf{xy}\} = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xy f_{\mathbf{x},\mathbf{y}}(x, y) dx dy \quad (33)$$

- Covariância:

$$\text{cov}\{\mathbf{x}, \mathbf{y}\} = E\{(\mathbf{x} - m_{\mathbf{x}})(\mathbf{y} - m_{\mathbf{y}})\} = E\{\mathbf{xy}\} - m_{\mathbf{x}}m_{\mathbf{y}} \quad (34)$$


Variáveis aleatórias múltiplas - V

- Sejam σ_x^2 e σ_y^2 as variâncias de \mathbf{x} e \mathbf{y} , respectivamente. A covariância normalizada com relação a $\sigma_x\sigma_y$ é chamada de *coeficiente de correlação*:

$$\rho_{\mathbf{x},\mathbf{y}} = \frac{\text{cov}\{\mathbf{x}, \mathbf{y}\}}{\sigma_x\sigma_y} . \quad (35)$$

- $\rho_{\mathbf{x},\mathbf{y}}$ indica o grau de *dependência linear* entre duas variáveis aleatórias.
- Pode-se mostrar que $|\rho_{\mathbf{x},\mathbf{y}}| \leq 1$.
- Se $\rho_{\mathbf{x},\mathbf{y}} = 0$, \mathbf{x} e \mathbf{y} são ditas *descorrelacionadas*.
- Pode-se verificar que se \mathbf{x} e \mathbf{y} são independentes, então $\rho_{\mathbf{x},\mathbf{y}} = 0$: *independência implica em ausência de correlação*.
- No entanto, ausência de correlação não necessariamente implica em independência estatística.

Processos aleatórios - I





Mapeamento de um espaço amostral em um *conjunto de funções temporais*.

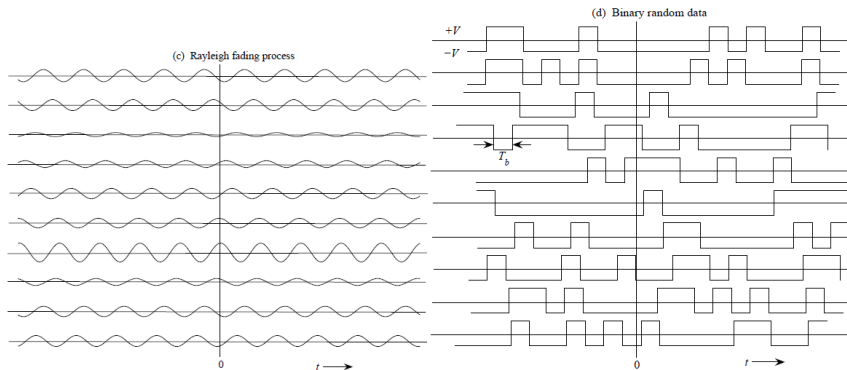
Processos aleatórios - II

- *Ensemble*: conjunto de possíveis funções temporais denotado por $\mathbf{x}(t)$, onde as funções temporais $x_1(t, \omega_1), x_2(t, \omega_2), x_3(t, \omega_3), \dots$, são membros específicos do ensemble.
- Em um dado instante $t = t_k$, temos a variável aleatória $\mathbf{x}(t_k)$.
- Em quaisquer dois instantes de tempo t_1 e t_2 , temos duas diferentes variáveis aleatórias $\mathbf{x}(t_1)$ e $\mathbf{x}(t_2)$. Qualquer relação entre elas é descrita pela PDF conjunta $f_{\mathbf{x}(t_1), \mathbf{x}(t_2)}(x_1, x_2; t_1, t_2)$.
- Descrição completa do processo aleatório é determinada pela PDF conjunta $f_{\mathbf{x}(t_1), \mathbf{x}(t_2), \dots, \mathbf{x}(t_N)}(x_1, x_2, \dots, x_N; t_1, t_2, \dots, t_N)$.
- PDFs conjuntas mais importantes:
 - Primeira ordem: $f_{\mathbf{x}(t)}(x; t)$
 - Segunda ordem: $f_{\mathbf{x}(t_1), \mathbf{x}(t_2)}(x_1, x_2; t_1, t_2)$

Exemplos de processos aleatórios - I



Exemplos de processos aleatórios - II



Classificação de processos aleatórios

- Baseada na mudança das estatísticas com o tempo o processo pode ser: *não-estacionário* ou *estacionário*.
- Diferentes níveis de estacionariedade:
 - Estritamente estacionário: a PDF conjunta de qualquer ordem é independente de um deslocamento temporal.
 - Estacionariedade de ordem N : a PDF conjunta não depende do deslocamento temporal, mas depende de espaçamentos no tempo:

$$f_{\mathbf{x}(t_1), \mathbf{x}(t_2), \dots, \mathbf{x}(t_N)}(x_1, x_2, \dots, x_n; t_1, t_2, \dots, t_N) = f_{\mathbf{x}(t_1+t), \mathbf{x}(t_2+t), \dots, \mathbf{x}(t_N+t)}(x_1, x_2, \dots, x_n; t_1 + t, t_2 + t, \dots, t_N + t)$$

- Estacionariedade de primeira ordem:

$$f_{\mathbf{x}(t_1)}(x; t_1) = f_{\mathbf{x}(t_1+t)}(x; t_1 + t) = f_{\mathbf{x}(t)}(x) \quad (36)$$

- Estacionariedade de segunda ordem:

$$\begin{aligned} f_{\mathbf{x}(t_1), \mathbf{x}(t_2)}(x_1, x_2; t_1, t_2) &= f_{\mathbf{x}(t_1+t), \mathbf{x}(t_2+t)}(x_1, x_2; t_1 + t, t_2 + t) \\ &= f_{\mathbf{x}(t_1), \mathbf{x}(t_2)}(x_1, x_2; \tau), \quad \tau = t_2 - t_1. \end{aligned}$$

Médias estatísticas ou momentos conjuntos

- Considere N variáveis aleatórias $\mathbf{x}(t_1), \mathbf{x}(t_2), \dots, \mathbf{x}(t_N)$. Os momentos conjuntos destas variáveis aleatórias são dados por:

$$E\{\mathbf{x}^{k_1}(t_1), \mathbf{x}^{k_2}(t_2), \dots, \mathbf{x}^{k_N}(t_N)\} = \int_{x_1=-\infty}^{\infty} \cdots \int_{x_N=-\infty}^{\infty} x_1^{k_1} x_2^{k_2} \cdots x_N^{k_N} f_{\mathbf{x}(t_1), \mathbf{x}(t_2), \dots, \mathbf{x}(t_N)}(x_1, x_2, \dots, x_N; t_1, t_2, \dots, t_N) dx_1 dx_2 \cdots dx_N,$$

para todos os inteiros $k_j \geq 1$ e $N \geq 1$.

- Vamos considerar somente os momentos de primeira e segunda ordem, i.e., $E\{\mathbf{x}(t)\}$ (média), $E\{\mathbf{x}^2(t)\}$ (valor quadrático médio) e $E\{\mathbf{x}(t_1)\mathbf{x}(t_2)\}$ (autocorrelação).

Valor médio ou primeiro momento

- O valor médio do processo em um tempo t é:

$$m_{\mathbf{x}}(t) = E\{\mathbf{x}(t)\} = \int_{-\infty}^{\infty} x f_{\mathbf{x}(t)}(x; t) dx . \quad (37)$$

- A média se dá ao longo do ensemble, e se a PDF varia com o tempo então o valor médio é uma função determinística do tempo.
- Se um processo é estacionário então a média é independente de t ou uma constante.

$$m_{\mathbf{x}} = E\{\mathbf{x}(t)\} = \int_{-\infty}^{\infty} x f_{\mathbf{x}}(x) dx . \quad (38)$$

Valor quadrático médio ou segundo momento

- O valor quadrático médio (MSV) é definido como:

$$\text{MSV}_{\mathbf{x}}(t) = E\{\mathbf{x}^2(t)\} = \int_{-\infty}^{\infty} x^2 f_{\mathbf{x}(t)}(x; t) dx \quad (\text{não-estac.})$$

$$\text{MSV}_{\mathbf{x}} = E\{\mathbf{x}^2(t)\} = \int_{-\infty}^{\infty} x^2 f_{\mathbf{x}}(x) dx \quad (\text{estac.})$$

- O segundo momento central (ou variância) é:

$$\sigma_{\mathbf{x}}^2(t) = E\{[\mathbf{x}(t) - m_{\mathbf{x}}(t)]^2\} = \text{MSV}_{\mathbf{x}}(t) - m_{\mathbf{x}}^2(t) \quad (\text{não-estac.})$$

$$\sigma_{\mathbf{x}}^2 = E\{[\mathbf{x}(t) - m_{\mathbf{x}}]^2\} = \text{MSV}_{\mathbf{x}} - m_{\mathbf{x}}^2 \quad (\text{estac.})$$

Correlação

- A função de autocorrelação descreve completamente a densidade espectral de potência do processo aleatório.
- Pode ser definida como a correlação entre duas variáveis aleatórias $\mathbf{x}_1 = \mathbf{x}(t_1)$ e $\mathbf{x}_2 = \mathbf{x}(t_2)$:

$$R_{\mathbf{x}}(t_1, t_2) = E\{\mathbf{x}(t_1)\mathbf{x}(t_2)\} = \int_{x_1=-\infty}^{\infty} \int_{x_2=-\infty}^{\infty} x_1 x_2 f_{\mathbf{x}_1, \mathbf{x}_2}(x_1, x_2; t_1, t_2) dx_1 dx_2$$

- Para um processo estacionário:

$$R_{\mathbf{x}}(\tau) = E\{\mathbf{x}(t)\mathbf{x}(t + \tau)\} = \int_{x_1=-\infty}^{\infty} \int_{x_2=-\infty}^{\infty} x_1 x_2 f_{\mathbf{x}_1, \mathbf{x}_2}(x_1, x_2; \tau) dx_1 dx_2$$

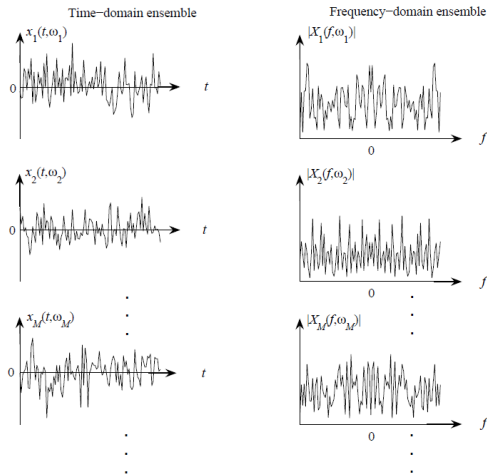
- Processo com *estacionariedade no sentido amplo* (WSS):
 - $E\{\mathbf{x}(t)\} = m_{\mathbf{x}}$ para qualquer t , e $R_{\mathbf{x}}(t_1, t_2) = R_{\mathbf{x}}(\tau)$ para $\tau = t_2 - t_1$.

Propriedades da autocorrelação de um processo WSS

- $R_x(\tau) = R_x(-\tau)$. É uma função par de τ , uma vez que o mesmo conjunto de valores é mediado ao longo do ensemble, independente da direção de translação.
- $|R_x(\tau)| \leq R_x(0)$. O valor máximo sempre ocorre em $\tau = 0$. Além disso, $R_x(0)$ é o valor médio quadrático do processo aleatório.
- Se para um certo τ_0 temos que $R_x(\tau_0) = R_x(0)$, então para qualquer inteiro k , $R_x(k\tau_0) = R_x(0)$.
- Se $m_x \neq 0$ então $R_x(\tau)$ possuirá uma componente constante igual a m_x^2 .
- Funções de autocorrelação não podem ter uma forma arbitrária. A restrição da forma surge do fato de que a transformada de Fourier de uma função de autocorrelação deve ser maior ou igual a zero, i.e., $\mathcal{F}\{R_x(\tau)\} \geq 0$.

Densidade espectral de potência de um processo aleatório - I

- Um processo aleatório é um sinal de energia infinita, portanto não se pode tirar diretamente sua transformada de Fourier.



Densidade espectral de potência de um processo aleatório - II

- É necessário determinar como a potência média do processo se distribui na frequência.
- Defina um processo truncado:

$$\mathbf{x}_T(t) = \begin{cases} \mathbf{x}(t), & -T \leq t \leq T \\ 0, & \text{c.c.} \end{cases} \quad (39)$$

- Considere a transformada de Fourier do processo truncado:

$$\mathbf{X}_T(f) = \int_{-\infty}^{\infty} \mathbf{x}_T(t) e^{-j2\pi ft} dt. \quad (40)$$

- Medie a energia sobre o tempo total, $2T$:

$$\mathbf{P} = \frac{1}{2T} \int_{-T}^T \mathbf{x}_T^2(t) dt = \frac{1}{2T} \int_{-\infty}^{\infty} |\mathbf{X}_T(f)|^2 df \quad (\text{Watts}) \quad (41)$$

Densidade espectral de potência de um processo aleatório - III

- Encontre o valor médio de \mathbf{P} :

$$E\{\mathbf{P}\} = E\left\{\frac{1}{2T} \int_{-T}^T \mathbf{x}_T^2(t) dt\right\} = E\left\{\frac{1}{2T} \int_{-\infty}^{\infty} |\mathbf{X}_T(f)|^2 df\right\} \quad (42)$$

- Toma-se o limite quando o período tende a infinito:

$$\lim_{T \rightarrow \infty} \frac{1}{2T} \int_{-T}^T E\{\mathbf{x}_T^2(t)\} dt = \lim_{T \rightarrow \infty} \frac{1}{2T} \int_{-\infty}^{\infty} E\{|\mathbf{X}_T(f)|^2\} df. \quad (43)$$

- Segue que:

$$\text{MSV}_{\mathbf{x}} = \int_{-\infty}^{\infty} \lim_{T \rightarrow \infty} \frac{E\{|\mathbf{X}_T(f)|^2\}}{2T} df \quad (\text{Watts}) \quad (44)$$

Densidade espectral de potência de um processo aleatório - IV

- Finalmente a *densidade espectral de potência* é dada por:

$$S_{\mathbf{x}}(f) = \lim_{T \rightarrow \infty} \frac{E \{ |\mathbf{X}_T(f)|^2 \}}{2T} \quad (\text{Watts/Hz}) \quad (45)$$

- Pode-se mostrar que a densidade espectral de potência e a função de autocorrelação formam um *par da transformada de Fourier*:

$$R_{\mathbf{x}}(\tau) \longleftrightarrow S_{\mathbf{x}}(f) = \int_{\tau=-\infty}^{\infty} R_{\mathbf{x}}(\tau) e^{-j2\pi f\tau} d\tau. \quad (46)$$

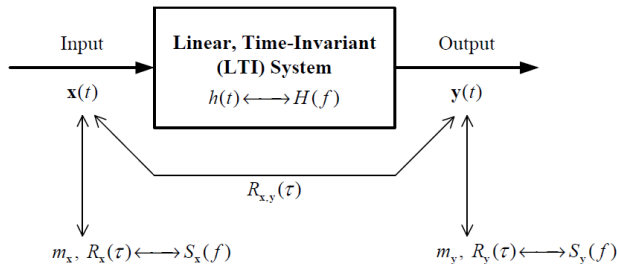
Média temporal e ergodicidade

- Um processo é *ergódico* quando qualquer membro do ensemble exibe o mesmo comportamento estatístico que todo o ensemble.
- Todas as médias temporais em um dado membro do ensemble são iguais à correspondente média do ensemble:

$$E\{\mathbf{x}^n(t)\} = \int_{-\infty}^{\infty} x^n f_{\mathbf{x}}(x) dx \quad (47)$$

- Em um processo ergódico: para medir diversas médias estatísticas, basta olhar para uma única realização do processo e encontrar a média temporal correspondente.
- Para um processo ser ergódico ele tem que ser estacionário. O reverso não é verdadeiro.

Processos aleatórios e sistemas LTI



$$m_y = E\{y(t)\} = E\left\{\int_{-\infty}^{\infty} h(\lambda)x(t-\lambda)d\lambda\right\} = m_x H(0) \quad (48)$$

$$S_y(f) = |H(f)|^2 S_x(f) \quad (49)$$

$$R_y(\tau) = h(\tau) * h(-\tau) * R_x(\tau) \quad (50)$$