

Otimização não-linear

Prof. Tarcisio F. Maciel, Dr.-Eng.

Colaboradores: Diego A. Sousa, M.-Eng., José Mairton B. da Silva Jr., M.-Eng.,
Francisco Hugo C. Neto, M.-Eng., e Yuri Victor L. de Melo, M.-Eng.

Universidade Federal do Ceará
Centro de Tecnologia
Programa de Pós-Graduação em Engenharia de Teleinformática

04/07/2018

Introdução

Conteúdo

1 Introdução

- O que é otimização?
- Problemas de otimização
- Classes de problemas de otimização

Conteúdo

1 Introdução

- O que é otimização?
- Problemas de otimização
- Classes de problemas de otimização

Introdução [NW06]

- Pessoas otimizam
 - Investidores → criam portfólios que minimizam riscos e atingem uma certa taxa de retorno
 - Fabricantes → maximizam eficiência no projeto e operação de suas plantas produtivas
 - Engenheiros → ajustam parâmetros reduzir custos e aumentar a eficiência de seus projetos
- A natureza otimiza
 - Sistemas físicos → tendem ao estado de mínima energia
 - Raios de luz → percorrem o caminho de menor tempo de percurso
 - Moléculas → se acomodam para minimizar a energia potencial dos elétrons
- Otimização é uma ferramenta importante para tomada de decisões e análise de sistemas físicos

Introdução [NW06]

- O que é otimização?
 - Dar a algo um rendimento ótimo, criando-lhe as condições mais favoráveis ou tirando o melhor partido possível; tornar algo ótimo ou ideal [dHF10]
- Porque otimizar?
 - Com otimização é possível melhorar o desempenho de um sistema, ou seja, deixar o sistema mais rápido e eficiente [NW06]
- Como otimizar?
 - Para otimizar é preciso definir o **objetivo**, uma medida que quantifica o desempenho do sistema
 - O objetivo depende de certos de certas características do sistema, chamadas de **variáveis** que otimizam o sistema
 - Por fim é frequente o uso de **restrições** que descrevem situações do sistema consideradas não desejáveis [NW06]

Conteúdo

1 Introdução

- O que é otimização?
- Problemas de otimização
- Classes de problemas de otimização

Elementos de um problema de otimização

- Uso da ferramenta de otimização → identificar alguns elementos
 - Objetivo → medida quantitativa do desempenho do sistema em estudo → lucro, tempo, energia, entre outros, ou uma combinação de fatores resultando em um escalar
 - Variáveis → parâmetros cujos valores podem ser ajustados e dos quais depende o desempenho do sistema
 - Restrições → condições às quais os valores da variáveis estão sujeitos
- Modelagem de problemas de otimização → Processo de identificação do objetivo, variáveis e restrições
 - Construção de um modelo apropriado → algumas vezes é o passo mais importante
 - Excessivamente simplista → não provê informação suficiente
 - Complexo demais → difícil de resolver
- Após modelado → solucionado usando um algoritmo de otimização
- Não há algoritmo universal → coleção de algoritmos especializados para cada tipo de problema
- Maiores benefícios → surgem quando o tipo do problema é conhecido
- Resultado do algoritmo → validado utilizando as condições de optimalidade

Modelo matemático de um problema de otimização

- Matematicamente, otimização é a maximização ou minimização de uma função objetivo sujeita a restrições sobre suas variáveis de otimização
- Em nossos modelos matemáticos, tipicamente:
 - $\mathbf{x} \in \mathbb{R}^n$ → vetor de **variáveis de otimização**
 - $f(\mathbf{x}) : \mathbb{R}^n \rightarrow \mathbb{R}$ → **função objetivo** que se deseja maximizar ou minimizar
 - $f_i(\mathbf{x}) : \mathbb{R}^n \rightarrow \mathbb{R}$ → as **restrições** de igualdade e desigualdade que \mathbf{x} deve satisfazer
- Logo, pode-se escrever um problema de otimização como

$$\mathbf{x}^\star = \underset{\mathbf{x} \in \mathbb{R}^n}{\text{minimize}} f(\mathbf{x}) \quad (1a)$$

$$\text{sujeito a } f_i(\mathbf{x}) = 0, \quad i = 1, 2, \dots, I, \quad (1b)$$

$$f_j(\mathbf{x}) \geq 0, \quad j = 1, 2, \dots, J, \quad (1c)$$

onde i e j são os índices para as restrições de igualdade e desigualdade, respectivamente, e \mathbf{x}^\star é uma **solução ótima**

Exemplo de problema de otimização: transporte de produtos [NW06]

- Uma companhia possui 02 fábricas F_1 e F_2 e 12 lojas R_1, R_2, \dots, R_{12} . Cada fábrica F_i pode produzir a_i toneladas de um produto (a_i é a capacidade da planta de produção) e cada loja possui uma demanda semanal de b_j toneladas do produto. O custo de transporte da fábrica F_i para a loja R_j de uma tonelada do produto é $c_{i,j}$. O problema é determinar as quantidades $x_{i,j} \in \mathbb{R}_+$ do produto que devem ser transportadas de cada fábrica para cada loja de modo a atender a todos os requisitos e minimizar o custo total.

Exemplo de problema de otimização: transporte de produtos [NW06]

- Uma companhia possui 02 fábricas F_1 e F_2 e 12 lojas R_1, R_2, \dots, R_{12} . Cada fábrica F_i pode produzir a_i toneladas de um produto (a_i é a capacidade da planta de produção) e cada loja possui uma demanda semanal de b_j toneladas do produto. O custo de transporte da fábrica F_i para a loja R_j de uma tonelada do produto é $c_{i,j}$. O problema é determinar as quantidades $x_{i,j} \in \mathbb{R}_+$ do produto que devem ser transportadas de cada fábrica para cada loja de modo a atender a todos os requisitos e minimizar o custo total. Esse problema pode ser formulado como segue:

$$\{x_{i,j}^*\} = \underset{\{x_{i,j}\}}{\text{minimize}} \quad \sum_{i=1}^2 \sum_{j=1}^{12} c_{i,j} x_{i,j} \quad (2a)$$

$$\text{sujeito a} \quad \sum_{j=1}^{12} x_{i,j} \leq a_i, \quad i = 1, 2 \quad (2b)$$

$$\sum_{i=1}^2 x_{i,j} \geq b_j, \quad j = 1, 2, \dots, 12 \quad (2c)$$

$$x_{i,j} \geq 0, \quad i = 1, 2 \quad \text{e} \quad j = 1, 2, \dots, 12 \quad (2d)$$

- Este problema é um **problema de otimização linear** → função custo e todas as restrições são funções lineares das variáveis do problema

 **Reescreva o problema acima em forma vetorial/matricial**

Exemplo de problema de otimização: minimização da soma das correlações espaciais [MK06]

- A correlação espacial $\rho_{i,j}$ entre os canais $\mathbf{h}_i = [h_{i,1} \quad h_{i,2} \quad \dots \quad h_{i,N}]$ e $\mathbf{h}_j = [h_{j,1} \quad h_{j,2} \quad \dots \quad h_{j,N}]$ do enlace direto de uma estação rádio base com N antenas para os terminais móveis i, j é dada por $\rho_{i,j} = \frac{|\mathbf{h}_i \mathbf{h}_j^H|}{\|\mathbf{h}_i\|_2 \|\mathbf{h}_j\|_2}$. Sabendo que existem K terminais móveis, selecione $G \leq N$ terminais móveis tal que a soma das correlações entre eles dois-a-dois seja mínima, ou seja, selecione os G terminais móveis com os canais menos correlacionados.

Exemplo de problema de otimização: minimização da soma das correlações espaciais [MK06]

- A correlação espacial $\rho_{i,j}$ entre os canais $\mathbf{h}_i = [h_{i,1} \quad h_{i,2} \quad \dots \quad h_{i,N}]$ e $\mathbf{h}_j = [h_{j,1} \quad h_{j,2} \quad \dots \quad h_{j,N}]$ do enlace direto de uma estação rádio base com N antenas para os terminais móveis i, j é dada por $\rho_{i,j} = \frac{|\mathbf{h}_i \mathbf{h}_j^H|}{\|\mathbf{h}_i\|_2 \|\mathbf{h}_j\|_2}$. Sabendo que existem K terminais móveis, selecione $G \leq N$ terminais móveis tal que a soma das correlações entre eles dois-a-dois seja mínima, ou seja, selecione os G terminais móveis com os canais menos correlacionados. Esse problema pode ser formulado como segue:

$$\mathbf{x}^\star = \underset{\mathbf{x}}{\text{minimize}} \quad \frac{1}{2} \mathbf{x}^T \mathbf{R} \mathbf{x}, \quad (3a)$$

$$\text{sujeito a} \quad \mathbf{1}^T \mathbf{x} = G, \quad (3b)$$

$$\mathbf{x} \in \mathbb{B}^K, \quad (3c)$$

onde $\mathbf{R} = [\rho_{i,j}]_{i,j}$, $i, j \in \{1, 2, \dots, K\}$.

- Este problema é um **problema de otimização binário quadrático** → função custo quadrática com variáveis de otimização binárias

 **Reescreva o problema acima utilizando somatórios**

Conteúdo

1 Introdução

- O que é otimização?
- Problemas de otimização
- Classes de problemas de otimização

Classes de problemas de otimização

- Natureza das variáveis de otimização, da função objetivo, e das restrições → diferentes tipos de problemas de otimização e algoritmos de otimização
- Variáveis de otimização
 - $\mathbf{x} \in \mathbb{R}^n$ → otimização contínua (mais fácil de resolver)
 - $\mathbf{x} \in \mathbb{Z}^n$ → otimização inteira (pode requerer relaxações contínuas)
 - $x_1, \dots, x_k \in \mathbb{R}$ e $x_{k+1}, \dots, x_n \in \mathbb{Z}$ → otimização inteira mista
- Função objetivo e restrições
 - $f(\mathbf{x})$, $f_i(\mathbf{x})$ e $f_j(\mathbf{x})$ lineares → Otimização linear
 - $f(\mathbf{x})$ e $f_i(\mathbf{x})$ convexas, $f_j(\mathbf{x})$ lineares → Otimização convexa
- Máximo/mínimo local → $f(\mathbf{x}^\star)$ é um máximo/mínimo local de $f(\mathbf{x})$ se existe um sub-espço aberto $\mathbb{A} \subset \mathbb{R}^n$ contendo \mathbf{x}^\star tal que $f(\mathbf{x}) \leq f(\mathbf{x}^\star)$, $\forall \mathbf{x} \in \mathbb{A}$.
- Máximo/mínimo global → $f(\mathbf{x}^\star)$ é um máximo/mínimo global de $f(\mathbf{x})$ se $f(\mathbf{x}) \leq f(\mathbf{x}^\star)$, $\forall \mathbf{x} \in \mathbb{R}^n$

Classes de problemas de otimização

- Algoritmos de otimização → especializados para cada tipo de problema
 - Otimização linear → método Simplex
 - Otimização convexa → método dos pontos interiores
 - Otimização linear inteira → método *branch-and-bound*
 - Otimização sem restrições → método de busca direta e métodos do gradiente
 - Otimização com restrições → métodos dos pontos interiores
 - Otimização determinística → restrições e parâmetros dados por funções bem definidas
 - Otimização estocástica → restrições ou parâmetros dependem de variáveis aleatórias

Exemplo de problema de otimização: mínimos quadrados [BV04]

- Considere o problema de minimizar a soma dos erros quadráticos entre as componentes de um vetor $\mathbf{y} = \mathbf{A}\mathbf{x}$ e um vetor de referência \mathbf{b} . Esse é um problema de mínimos quadrados sem restrições que pode ser escrito como

$$\mathbf{x}^{\star} = \underset{\mathbf{x}}{\text{minimize}} \|\mathbf{A}\mathbf{x} - \mathbf{b}\|_2^2 \quad (4)$$

Exemplo de problema de otimização: mínimos quadrados [BV04]

- Considere o problema de minimizar a soma dos erros quadráticos entre as componentes de um vetor $y = Ax$ e um vetor de referência b . Esse é um problema de mínimos quadrados sem restrições que pode ser escrito como

$$x^{\star} = \underset{x}{\text{minimize}} \|Ax - b\|_2^2 \quad (4)$$

- Note que

$$\begin{aligned} \|Ax - b\|_2^2 &= (Ax - b)^T (Ax - b) = (x^T A^T - b^T)(Ax - b) \\ &= x^T A^T Ax - x^T A^T b - b^T Ax - b^T b = x^T A^T Ax - 2b^T Ax - b^T b \end{aligned} \quad (5)$$

- Derivando a equação acima em relação a x e igualando a 0 temos

$$\frac{d}{dx} (x^T A^T Ax - 2b^T Ax - b^T b) = 0 \Rightarrow 2A^T Ax - 2A^T b = 0 \Rightarrow \boxed{x^{\star} = (A^T A)^{-1} A^T b} \quad (6)$$

 Liste as classes de problemas de otimização às quais esse problema pertence

Conjuntos convexos e funções convexas

Conteúdo

2 Conjuntos convexos

- Conjuntos afins e convexos
- Operações sobre conjuntos que preservam convexidade
- Hiperplanos, cones e desigualdades generalizadas

3 Propriedades básicas

4 Bibliografia

Conteúdo

2 Conjuntos convexos

- Conjuntos afins e convexos
- Operações sobre conjuntos que preservam convexidade
- Hiperplanos, cones e desigualdades generalizadas


3 Propriedades básicas

4 Bibliografia

Conjuntos afins


• Linha e segmentos

- Sejam os pontos $x_1, x_2 \in \mathbb{R}^n$ com $x_1 \neq x_2 \rightarrow$ pontos y da forma $y = \theta x_1 + (1 - \theta)x_2$ com $\theta \in \mathbb{R}, 0 \leq \theta \leq 1$, formam um segmento fechado ligando x_1 a x_2
- Representando $y = x_2 + \theta(x_1 - x_2) \rightarrow$ Ponto base x_2 e direção $(x_1 - x_2)$ apontando de x_2 para x_1 e escalonada por θ



• Conjuntos afins


- Um conjunto $A \subset \mathbb{R}^n$ é afim \rightarrow para qualquer $x_1, x_2 \in A \subset \mathbb{R}$ e $\theta \in \mathbb{R}$, o segmento de reta $y = \theta x_1 + (1 - \theta)x_2 \in A$
- Combinação afim $\rightarrow y = \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_k x_k \in A \subset \mathbb{R}$, com $\theta_1 + \theta_2 + \dots + \theta_k = 1$



Conjuntos convexos


Conjuntos convexos

- Um conjunto $\mathbb{A} \subset \mathbb{R}^n$ é convexo caso um segmento entre $\mathbf{x}_1, \mathbf{x}_2 \in \mathbb{A}$ e $0 \leq \theta \leq 1$, pertença a \mathbb{A} , ou seja, $\theta \mathbf{x}_1 + (1 - \theta) \mathbf{x}_2 \in \mathbb{A}$
- Em termos geométricos, um conjunto convexo é um conjunto sem buracos ou reentrâncias



Invólucro convexo (*convex hull*)

- Dado um conjunto \mathbb{A} , o invólucro convexo de \mathbb{A} é o menor conjunto convexo que engloba \mathbb{A} , sendo denotado por $\text{conv} \{\mathbb{A}\} = \{\theta_1 \mathbf{x}_1 + \dots + \theta_k \mathbf{x}_k \mid \mathbf{x}_i \in \mathbb{A}, \theta_i \geq 0, i = 1, \dots, k, \theta_1 + \dots + \theta_k = 1\}$



Conteúdo

2 Conjuntos convexos

- Conjuntos afins e convexos
- Operações sobre conjuntos que preservam convexidade
- Hiperplanos, cones e desigualdades generalizadas

3 Propriedades básicas

4 Bibliografia

Operações sobre conjuntos que preservam convexidade

- Interseção \rightarrow se A_α é convexo para todo $\alpha \in \mathbb{R}$, então

$$\bigcap_{\alpha \in \mathbb{R}} A_\alpha \quad \text{também é convexo} \quad (7)$$

- Multiplicação por escalar \rightarrow se $A \subseteq \mathbb{R}^n$ é convexo e $\alpha \in \mathbb{R}$, então

$$\alpha A = \{\alpha \mathbf{x} \mid \mathbf{x} \in A\} \quad \text{também é convexo} \quad (8)$$

- Translação \rightarrow se $A \subseteq \mathbb{R}^n$ é convexo e $\alpha \in \mathbb{R}^n$, então

$$A + \alpha = \{\mathbf{x} + \alpha \mid \mathbf{x} \in A\} \quad \text{também é convexo} \quad (9)$$

- Soma \rightarrow se A_1 e A_2 são convexos, então

$$A_1 + A_2 = \{\mathbf{x} + \mathbf{y} \mid \mathbf{x} \in A_1, \mathbf{y} \in A_2\} \quad \text{também é convexo} \quad (10)$$

- Produto cartesiano \rightarrow se A_1 e A_2 são convexos, então

$$A_1 \times A_2 = \{(\mathbf{x}, \mathbf{y}) \mid \mathbf{x} \in A_1, \mathbf{y} \in A_2\} \quad \text{também é convexo} \quad (11)$$

Conteúdo

2 Conjuntos convexos

- Conjuntos afins e convexos
- Operações sobre conjuntos que preservam convexidade
- Hiperplanos, cones e desigualdades generalizadas

3 Propriedades básicas

4 Bibliografia

Hiperplanos, cones e desigualdades generalizadas

- Hiperplano \rightarrow conjunto de pontos, podendo ser escrito como

$$\{\mathbf{x} \mid \mathbf{a}^T(\mathbf{x} - \mathbf{x}_0) = 0\} \quad (12)$$

onde $\mathbf{a} \in \mathbb{R}^n$, $\mathbf{a} \neq \mathbf{0}$, e \mathbf{x}_0 determina o offset do hiperplano. Um hiperplano divide o espaço em dois semi-espacos

- Semi-espaco \rightarrow conjunto da forma

$$\{\mathbf{x} \mid \mathbf{a}^T(\mathbf{x} - \mathbf{x}_0) \leq 0\} \quad (13)$$

onde $\mathbf{a} \in \mathbb{R}^n$, $\mathbf{a} \neq \mathbf{0}$

TODO

Adicionar figuras

Hiperplanos, cones e desigualdades generalizadas

- Cone é conjunto de pontos tais que

$$\forall \mathbf{x} \in \mathbb{A} \subset \mathbb{R}^n \text{ e } \theta \geq 0, \theta \in \mathbb{R}_+$$

$$\theta \mathbf{x} \in \mathbb{A}, \forall \mathbf{x} \in \mathbb{A} \quad (14)$$

- Cone Convexo é um conjunto que é simultaneamente um cone e convexo, ou seja, para qualquer $\mathbf{x}_1, \mathbf{x}_2 \in \mathbb{A} \subset \mathbb{R}^n$ e $\theta_1, \theta_2 \geq 0, \theta_1$

$$\theta_1 \mathbf{x}_1 + \theta_2 \mathbf{x}_2 \in \mathbb{A} \quad (15)$$

TODO

Adicionar figuras

Conjuntos Convexos

- A bola Euclidiana com o centro em \mathbf{x}_c e raio r é representada por

$$B(\mathbf{x}_c, r) = \{\mathbf{x}_c + r\mathbf{u} \mid \|\mathbf{u}\|_2 \leq 1\} \quad (16)$$

- O elipsoide com o centro em \mathbf{x}_c é um conjunto representado na forma

$$\mathcal{E} = \{\mathbf{x} \mid (\mathbf{x} - \mathbf{x}_c)^T \mathbf{P}^{-1}(\mathbf{x} - \mathbf{x}_c) \leq 1\} \quad (17)$$

onde $\mathbf{P} \in \mathbb{A} \subset \mathbb{S}_{++}^n$, ou seja, \mathbf{P} é uma matriz simétrica positiva definida

TODO

Adicionar figuras

Conjuntos Convexos

- Poliedro

- O poliedro é definido como um conjunto de igualdades lineares e inequações.

$$Ax \leq b, Cx = d \quad (18)$$

onde \leq é o símbolo que representa desigualdade componente a componente entre vetores.

- Dessa forma, a representação do poliedro pode escrita como:

$$P = \{x \mid Ax \leq b, Cx = d\} \quad (19)$$

Conjuntos Convexos

- Norma da Bola com centro x_c e raio r é representado por:

$$\{x \mid \|x - x_c\| \leq r\} \quad (20)$$

onde $\|\cdot\|$ é a norma.

- A norma do cone pode ser definido como:

$$\{(x, t) \in \mathbb{R}^n + 1 \mid \|x\| \leq t\} \quad (21)$$

Conjuntos Convexos

- PSD (Cone positivo semidefinido) é um cone formado a parti das matrizes positivas semidefinidas que utiliza a notação:

$$\mathbb{A}_+^n = \{X \in \mathbb{A}^n \mid X \succ 0\} \quad (22)$$

onde \mathbb{A}^n denota o conjunto de matrizes simetricas. Dessa forma o conjunto \mathbb{A}_+^n é um cone positivo semidefinido, se $\theta_1, \theta_2 \geq 0$ e $A, B \in \mathbb{A}_+^n$, assim $\theta_1 A + \theta_2 B \in \mathbb{A}_+^n$.

Conjuntos Convexos

- Desigualdade generalizadas

- Um cone pode ser usado para definir a desigualdade generalizada, que é similar a relação de ordem apresentada em \mathbb{R} . Desta forma, para um cone K onde $K \subseteq \mathbb{R}^n$, as desigualdades não estritas e estritas \leq_K e $<_K$, respectivamente são definidas da seguinte maneira:

$$x \leq_K y \Leftrightarrow y - x \in K \quad (23a)$$

$$x <_K y \Leftrightarrow y - x \in \text{int}(K) \quad (23b)$$

onde $\text{int}(K)$ representa o interior do conjunto K .

- Propriedades

- Se $x \leq_K y$ e $u \leq_K v$, então $x + u \leq_K y + v$
- Se $x \leq_K y$ e $y \leq_K u$, então $x \leq_K u$
- Se $x \leq_K y$ e $y \leq_K x$, então $x = y$
- Se $x <_K y$ e $u \leq_K v$, então $x + u <_K y + v$

Conteúdo

2 Conjuntos convexos

3 Propriedades básicas

- Propriedades básicas e exemplos
- Operações que preservam convexidade
- Função conjugada
- Funções quasi-convexas
- Funções log-côncavas e log-convexas
- Convexidade e inequações generalizadas

4 Bibliografia

Conteúdo

2 Conjuntos convexos

3 Propriedades básicas

- Propriedades básicas e exemplos
- Operações que preservam convexidade
- Função conjugada
- Funções quasi-convexas
- Funções log-côncavas e log-convexas
- Convexidade e inequações generalizadas

4 Bibliografia

Propriedades básicas

- Uma função $f : \mathbb{R}^n \rightarrow \mathbb{R}$ é convexa somente se o domínio de f ($\text{dom } f$) for convexo e $\forall x, y \in \text{dom } f$, e $0 \leq \theta \leq 1$ (24) for verdade.

$$f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y) \quad (24)$$

- Observando a condição (24), temos que em uma função $f(\cdot)$ convexa, qualquer segmento de reta entre os pontos $(x, f(x))$ e $(y, f(y))$ estará acima de $f(\cdot)$ entre os valores x e y , como mostrado na figura abaixo.

Propriedades básicas

- Dizemos que uma função $f(\cdot)$ é estritamente convexa se a desigualdade ocorrer sempre para $0 < \theta < 1$ e $x \neq y$, ou seja,

$$f(\theta x + (1 - \theta)y) < \theta f(x) + (1 - \theta)f(y) \quad (25)$$

- Define-se uma função $f(\cdot)$ como côncava, se $-f(\cdot)$ for convexa.
- Funções afins são convexas e côncavas, visto que

$$f(\theta x + (1 - \theta)y) = \theta f(x) + (1 - \theta)f(y) \quad (26)$$

para $0 \leq \theta \leq 1$.

Propriedades básicas

- Uma função $f(\cdot)$ é convexa se e somente se ela é convexa quando restrita a qualquer linha que intercepta seu domínio. Ou seja, $f(x)$ é convexa se e somente se para todo $x \in \text{dom } f$ e para todo v , a função $g(t) = f(x + tv)$ é convexa no domínio $\{t | x + tv \in \text{dom } f\}$.
- Esta propriedade é muito importante, pois pode-se avaliar a convexidade de uma função, restringindo-a a uma linha.

Extensão

- As vezes é conveniente que o domínio da função $f(\cdot)$ seja estendido para todo \mathbb{R}^n , atribuindo o valor ∞ para $f(x)$ quando $x \notin \text{dom } f$.
- Assim, a extensão de $f(x)$, $\tilde{f} : \mathbb{R}^n \rightarrow \mathbb{R} \cup \infty$ é definida como:

$$\tilde{f}(x) = \begin{cases} f(x) & x \in \text{dom } f \\ \infty & x \notin \text{dom } f \end{cases} \quad (27)$$

- Essa extensão é útil pelo fato de simplificar a notação e de não haver a necessidade de se explicitar o seu domínio.
- De modo análogo, podemos estender funções côncavas adicionando $-\infty$ a seu domínio.

Condições de primeira ordem

- Seja $f(\cdot)$ uma função diferenciável, então $f(\cdot)$ é convexo se e somente se o $\text{dom } f$ for convexo e

$$f(y) \geq f(x) + \nabla f(x)^T(y - x) \quad \forall x, y \in \text{dom } f \quad (28)$$

- Note que o segundo termo de (28) é uma função afim em relação a y e que é igual a aproximação de primeira ordem de Taylor de $f(y)$ em torno de x .

Condições de primeira ordem

- Assim, se a aproximação de primeira ordem de Taylor de uma função sempre representar um subestimador global, a função $f(\cdot)$ é convexa.
- De (28), podemos ver que a partir da informação local (x e $\nabla f(x)$) nós podemos derivar a informação global (subestimador global) de $f(\cdot)$.
- Podemos ainda deduzir de (28) que se $\nabla f(x) = 0$, então $f(y) \geq f(x)$, o que implica dizer que o ponto $(x, f(x))$ representa o mínimo global de $f(\cdot)$.
- Para que $f(\cdot)$ seja estritamente convexo, temos que a desigualdade em (28) tem que ser estrita, ou seja,

$$f(y) > f(x) + \nabla f(x)^T(y - x) \quad \forall x, y \in \text{dom } f \text{ e } x \neq y \quad (29)$$

Condições de segunda ordem

- Seja $f(\cdot)$ duas vezes diferenciável. $f(\cdot)$ é convexo se e somente se o $\text{dom } f$ é convexo e sua Hessiana é semi-positiva definida $\forall x \in \text{dom } f$, ou seja,

$$\nabla^2 f(x) \geq 0. \quad (30)$$

- No caso das funções reais (30) se reduz a $f''(x) \geq 0$, o que implica dizer que $f(\cdot)$ é não decrescente.
- Geograficamente, a condição (30) pode ser interpretada como o gráfico da função possuir curvatura sempre positiva.
- De modo análogo, temos que $f(\cdot)$ é côncava se e somente se

$$\nabla^2 f(x) \leq 0. \quad (31)$$

- Se $\nabla^2 f(x) > 0$, então $f(\cdot)$ é estritamente convexa, contudo, **a recíproca não é verdadeira!**

Conjunto de subníveis

- O conjunto de subnível α de uma função $f : \mathbb{R}^n \rightarrow \mathbb{R}$ é definido como:

$$C_\alpha = \{x \in \text{dom } f \mid f(x) \leq \alpha\} \quad (32)$$

- Conjuntos de subnível de uma função convexa são convexos para qualquer α .
- Prova: Seja $x, y \in \mathbb{A}_\alpha$, então $f(x) \leq \alpha$ e $f(y) \leq \alpha$. Assim, de (24), temos que:

$$\begin{aligned} f(\theta x + (1 - \theta)y) &\leq \theta f(x) + (1 - \theta)f(y) \\ &\leq \theta \alpha + (1 - \theta)\alpha \leq \alpha \end{aligned}$$

Logo, $\theta x + (1 - \theta)y \in \mathbb{A}_\alpha$

- **A recíproca não é verdadeira!** Uma função pode ter todos seus subníveis convexos e não ser convexa.

Epígrafo e Hipografo

- O grafo de uma função $f : \mathbb{R}^n \rightarrow \mathbb{R}$ é definido como

$$\{(x, f(x)) | x \in \text{dom } f\}, \quad (33)$$

que é um subconjunto de \mathbb{R}^{n+1} .

- O epígrafo de $f(\cdot)$ é definido como:

$$\text{epi } f = \{(x, t) | x \in \text{dom } f, f(x) \leq t\} \quad (34)$$

que é um subconjunto de \mathbb{R}^{n+1} .

Epígrafo e Hipografo

- O epígrafo faz a ligação entre funções e conjuntos convexos.
- Uma função $f(\cdot)$ é convexa se e somente se seu epígrafo representar um conjunto convexo.
- O hipografo de uma função é definido como sendo

$$\text{hypo } f = \{(x, t) | x \in \text{dom } f, t \leq f(x)\} \quad (35)$$

- A função $f(\cdot)$ é côncava se e somente seu hipografo for **convexo**.

Desigualdade de Jensen e extensões



Conteúdo

2 Conjuntos convexos

3 Propriedades básicas

- Propriedades básicas e exemplos
- Operações que preservam convexidade
- Função conjugada
- Funções quasi-convexas
- Funções log-côncavas e log-convexas
- Convexidade e inequações generalizadas

4 Bibliografia

Conteúdo

2 Conjuntos convexos

3 Propriedades básicas

- Propriedades básicas e exemplos
- Operações que preservam convexidade
- Função conjugada
- Funções quasi-convexas
- Funções log-côncavas e log-convexas
- Convexidade e inequações generalizadas

4 Bibliografia

Conteúdo

2 Conjuntos convexos

3 Propriedades básicas

- Propriedades básicas e exemplos
- Operações que preservam convexidade
- Função conjugada
- Funções quasi-convexas
- Funções log-côncavas e log-convexas
- Convexidade e inequações generalizadas

4 Bibliografia

Conteúdo

2 Conjuntos convexos

3 Propriedades básicas

- Propriedades básicas e exemplos
- Operações que preservam convexidade
- Função conjugada
- Funções quasi-convexas
- Funções log-côncavas e log-convexas
- Convexidade e inequações generalizadas

4 Bibliografia

Conteúdo

2 Conjuntos convexos

3 Propriedades básicas

- Propriedades básicas e exemplos
- Operações que preservam convexidade
- Função conjugada
- Funções quasi-convexas
- Funções log-côncavas e log-convexas
- Convexidade e inequações generalizadas

4 Bibliografia

Conteúdo

2 Conjuntos convexos

3 Propriedades básicas

4 Bibliografia

Bibliografia

- [BV04] S. Boyd and L. Vandenberghe, *Convex optimization*, 1st ed. Cambridge University Press, 2004.
- [dHF10] A. B. de Holanda Ferreira, *Dicionário do Aurélio*, 5th ed. Positivo Editora, 2010.
- [MK06] T. F. Maciel and A. Klein, “A low-complexity SDMA grouping strategy for the downlink of Multi-User MIMO systems,” in *Proceedings of the IEEE Personal, Indoor and Mobile Radio Communications (PIMRC)*, sep 2006.
- [NW06] J. Nocedal and S. J. Wright, *Numerical optimization*, 2nd ed., T. V. Mikosh, S. M. Robinson, and S. I. Resnick, Eds. Springer, 2006.